Proyecto de aprendizaje máquina

Comparación experimental de algoritmos

Propósito

Desarrollar una investigación aplicada en la que se comparen dos algoritmos de aprendizaje máquina para resolver un problema de clasificación o regresión. El trabajo deberá relacionar el contexto del problema con la selección de métricas, los métodos de aprendizaje, el diseño experimental y el análisis estadístico de los resultados.

Cada equipo trabajará con uno de los siguientes seis proyectos: cuatro de clasificación y dos de regresión. Los conjuntos de datos cuentan con predictores numéricos y no presentan valores faltantes. No se requieren actividades de limpieza, reparación o imputación.

Organización de la asignación

- Proyectos 1 a 4: clasificación de tumores, tipos de vidrio, variedades de trigo y autenticación de billetes.
- Proyectos 5 y 6: estimación de la resistencia del concreto y predicción del ruido de perfiles aerodinámicos.
- Desarrollo: formulación del problema, selección de métricas y algoritmos, preparación, experimentación y análisis estadístico.
- Entregables: artículo, presentación, código reproducible y resultados experimentales.

Proyectos disponibles

1 Clasificación de tumores malignos con pocos datos

Dataset: Breast Cancer Wisconsin — Diagnostic

Descripción: Contiene 569 muestras y 30 características numéricas que describen propiedades de núcleos celulares, como radio, textura, perímetro, área y concavidad. La variable objetivo distingue entre muestras benignas y malignas. El identificador del registro no forma parte de los predictores.

Objetivo: Desarrollar y comparar modelos para identificar muestras malignas, considerando que no detectar una muestra maligna tiene consecuencias diferentes a clasificar una muestra benigna como maligna.

Dificultad: Cantidad limitada de observaciones en relación con el número de características y consecuencias distintas de los errores. La evaluación deberá considerar la identificación de la clase de interés y la estabilidad de los resultados.

2 Clasificación de tipos de vidrio con clases minoritarias

Dataset: Glass Identification

Descripción: Contiene 214 observaciones y nueve características numéricas relacionadas con el índice de refracción y la composición química del vidrio. Incluye seis clases presentes, correspondientes a diferentes usos del material. El identificador del registro no forma parte de los predictores.

Objetivo: Desarrollar y comparar modelos para identificar el tipo de vidrio a partir de sus propiedades, procurando reconocer también los tipos menos representados, en un contexto de identificación de fragmentos para análisis forense.

Dificultad: Distribución desigual entre clases y pocos ejemplos de algunos tipos de vidrio. Un resultado global favorable puede ocultar deficiencias importantes en las clases minoritarias.

Proyectos disponibles

3 Clasificación de variedades de trigo mediante características geométricas

Dataset: Seeds

Descripción: Contiene 210 observaciones de tres variedades de trigo —Kama, Rosa y Canadian—, con 70 muestras por variedad. Cada observación tiene siete características numéricas: área, perímetro, compacidad, longitud, ancho, coeficiente de asimetría y longitud del surco.

Objetivo: Desarrollar y comparar modelos para identificar variedades de trigo a partir de mediciones geométricas, como apoyo a la clasificación de granos y al control de identidad varietal.

Dificultad: Disponibilidad reducida de ejemplos para aprender y evaluar. Aunque las clases están balanceadas, es necesario determinar si el rendimiento es consistente entre variedades y si las conclusiones se mantienen ante cambios en las muestras utilizadas.

4 Clasificación para autenticación de billetes

Dataset: Banknote Authentication

Descripción: Contiene 1,372 observaciones y cuatro características numéricas extraídas de imágenes de especímenes genuinos y falsificados: varianza, asimetría, curtosis y entropía. La variable objetivo identifica su clase. Las características ya están calculadas; no se requiere procesar imágenes.

Objetivo: Desarrollar y comparar modelos para distinguir especímenes genuinos de falsificados, considerando su posible aplicación como apoyo a un procedimiento de autenticación.

Dificultad: Los errores tienen consecuencias diferentes: aceptar una falsificación puede ocasionar una pérdida económica, mientras que rechazar un billete genuino genera revisiones adicionales y afecta la operación. La evaluación deberá considerar ambos tipos de error y justificar su importancia en el contexto planteado.

Proyectos disponibles

5 Regresión para estimar la resistencia del concreto

Dataset: Concrete Compressive Strength

Descripción: Contiene 1,030 observaciones y ocho predictores numéricos: cantidades de cemento, escoria, ceniza volante, agua, superplastificante, agregado grueso, agregado fino y edad. La variable objetivo es la resistencia a compresión, expresada en MPa.

Objetivo: Desarrollar y comparar modelos para estimar la resistencia del concreto a partir de su composición y edad, proporcionando estimaciones útiles para evaluar el comportamiento de las mezclas.

Dificultad: Relaciones no lineales y posibles errores de gran magnitud. Sobreestimar la resistencia tiene implicaciones diferentes a subestimarla, por lo que no basta con describir el comportamiento promedio sin examinar los errores relevantes para el contexto.

6 Regresión para predecir el ruido de perfiles aerodinámicos

Dataset: Airfoil Self-Noise

Descripción: Contiene 1,503 observaciones obtenidas en pruebas aerodinámicas y acústicas. Sus cinco predictores numéricos son frecuencia, ángulo de ataque, longitud de cuerda, velocidad del flujo y espesor de desplazamiento del lado de succión. La variable objetivo es el nivel de presión sonora escalado, expresado en decibeles.

Objetivo: Desarrollar y comparar modelos para estimar el ruido producido por perfiles aerodinámicos bajo diferentes condiciones, como apoyo a la identificación de configuraciones con menor emisión sonora.

Dificultad: Relaciones no lineales entre las condiciones físicas y el ruido. La respuesta está expresada en una escala logarítmica, por lo que deberá justificarse cómo se cuantifican e interpretan los errores. Un buen resultado general puede ocultar deficiencias en las condiciones de mayor emisión sonora.

Desarrollo del proyecto

1 Formulación del problema

Planteen una pregunta de investigación congruente con el objetivo del proyecto. Delimiten el alcance del estudio e identifiquen la variable objetivo, los predictores y las consecuencias de los errores en el contexto de aplicación.

Describan el conjunto de datos y las características que puedan influir en el aprendizaje y la evaluación.

2 Selección y justificación de métricas

Seleccionen una métrica principal que permita evaluar el cumplimiento del objetivo. Justifiquen su elección considerando las características del dataset, la distribución de las clases o de la respuesta y las consecuencias de los errores.

Se recomienda incorporar métricas complementarias que permitan analizar aspectos del rendimiento que la métrica principal no describa por completo.

Podrán explorar otras métricas, incluidas aquellas no revisadas en clase, si consideran pertinente o necesario su uso. En cada caso deberán explicar cómo se calculan, cómo se interpretan, por qué son adecuadas para el problema y qué información adicional aportan.

Establezcan la métrica principal antes de realizar la comparación final. No deberá seleccionarse únicamente porque favorezca a alguno de los algoritmos.

3 Selección de algoritmos

Elijan dos algoritmos de aprendizaje de enfoques distintos. Pueden utilizar métodos clásicos o ensambles.

Expliquen sus fundamentos, justifiquen su pertinencia para el problema y documenten sus configuraciones. Si realizan ajustes de hiperparámetros, describan y justifiquen el procedimiento utilizado.

4 Preparación para el aprendizaje

Identifiquen las transformaciones numéricas que requiera cada algoritmo y justifiquen su aplicación. Cualquier transformación que aprenda parámetros deberá ajustarse exclusivamente con los datos de entrenamiento.

Los identificadores de registros no deberán utilizarse como predictores. En clasificación, las etiquetas numéricas de las clases representan categorías, no cantidades ni relaciones de orden.

Desarrollo del proyecto

5 Diseño y ejecución de la experimentación

Seleccionen y apliquen un diseño experimental que permita responder la pregunta de investigación y comparar los algoritmos de forma justa.

Justifiquen la organización de los datos, las condiciones de entrenamiento y evaluación y las decisiones necesarias para evitar fuga de información. Ambos algoritmos deberán evaluarse bajo condiciones comparables.

Documenten las particiones, semillas, configuraciones y versiones de software necesarias para reproducir el experimento. No presenten únicamente la ejecución más favorable.

6 Análisis estadístico

Seleccionen y apliquen una prueba estadística compatible con el diseño experimental y la medida de rendimiento elegida.

Presenten las hipótesis, el nivel de significancia, los supuestos de la prueba, el estadístico obtenido y su interpretación. Distingan entre una diferencia estadísticamente significativa y una diferencia relevante para el problema.

No encontrar evidencia de una diferencia significativa no demuestra que los algoritmos tengan un rendimiento igual o equivalente.

7 Discusión de resultados

Analicen los resultados en relación con el objetivo y las dificultades del proyecto. Examinen los errores relevantes, la variabilidad del rendimiento y las limitaciones de la comparación.

La conclusión deberá responder la pregunta de investigación y estar respaldada por la evidencia experimental y estadística.

Reporte en formato de artículo

Elaboren un artículo utilizando la plantilla Springer LNCS, disponible para Word y LaTeX.

Plantilla: Plantillas oficiales Springer LNCS

Título: Identificar el problema y el propósito del estudio.

Abstract: Sintetizar el problema, objetivo, metodología, resultados principales y conclusión.

Introducción: Presentar el contexto, la relevancia del problema, la pregunta de investigación, el objetivo y el alcance.

Marco teórico: Explicar los fundamentos de los algoritmos, métricas y procedimientos de evaluación seleccionados. Incorporar trabajos relacionados.

Metodología: Describir los datos, los predictores, las transformaciones y el procedimiento propuesto. Justificar las decisiones.

Experimentación: Detallar el diseño experimental, las configuraciones y los procedimientos de entrenamiento, evaluación y contraste estadístico.

Resultados: Presentar tablas y gráficas pertinentes, el análisis estadístico y la discusión de los hallazgos.

Conclusiones: Responder la pregunta de investigación, valorar los resultados y reconocer limitaciones y posibles extensiones.

Referencias: Citar el dataset y las fuentes académicas y técnicas utilizadas.

Presentación del proyecto

Preparen diapositivas basadas en el artículo. La exposición deberá comunicar el problema, el objetivo, las características del dataset, las decisiones metodológicas, la experimentación, los resultados y las conclusiones.

Utilicen tablas y gráficas legibles. Expliquen y defiendan las decisiones del equipo, evitando copiar párrafos completos del artículo. Los resultados presentados deberán coincidir con los del reporte.

Entregables

- Artículo en PDF y formato editable.
- Diapositivas en PDF y formato editable.
- Código reproducible con instrucciones de ejecución.
- Archivo con los resultados experimentales utilizados en el análisis.