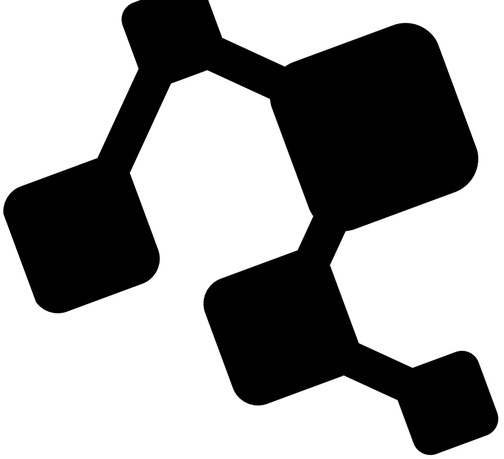
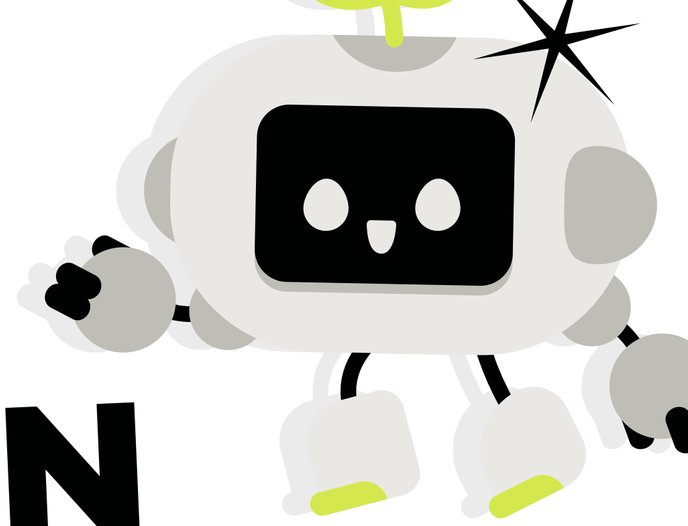
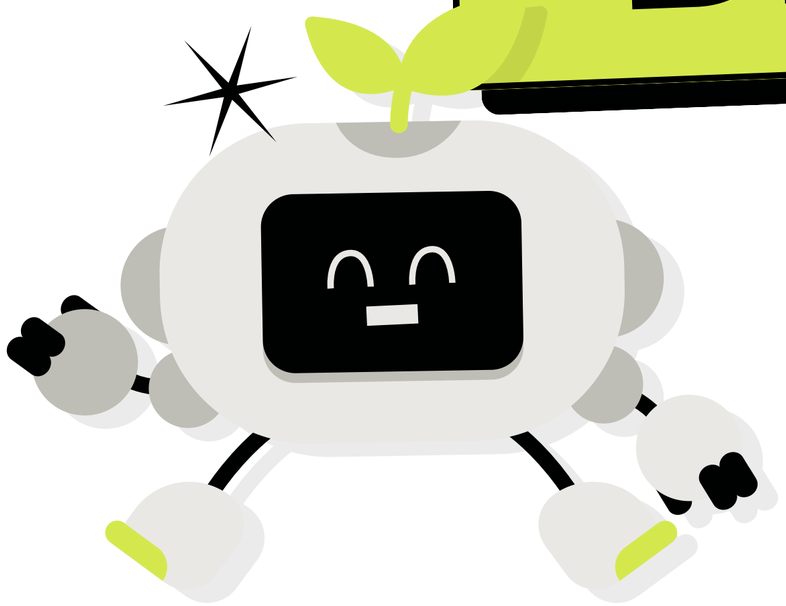
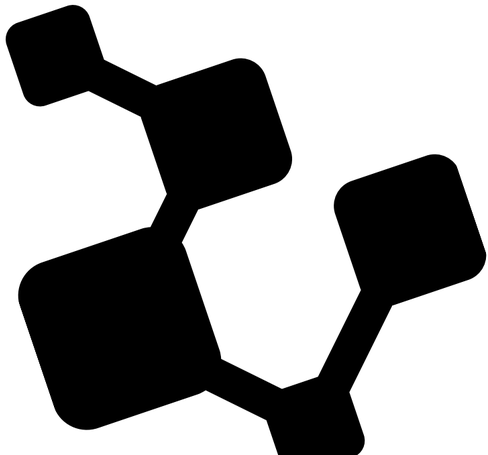




CLASIFICACIÓN DE SILUETAS

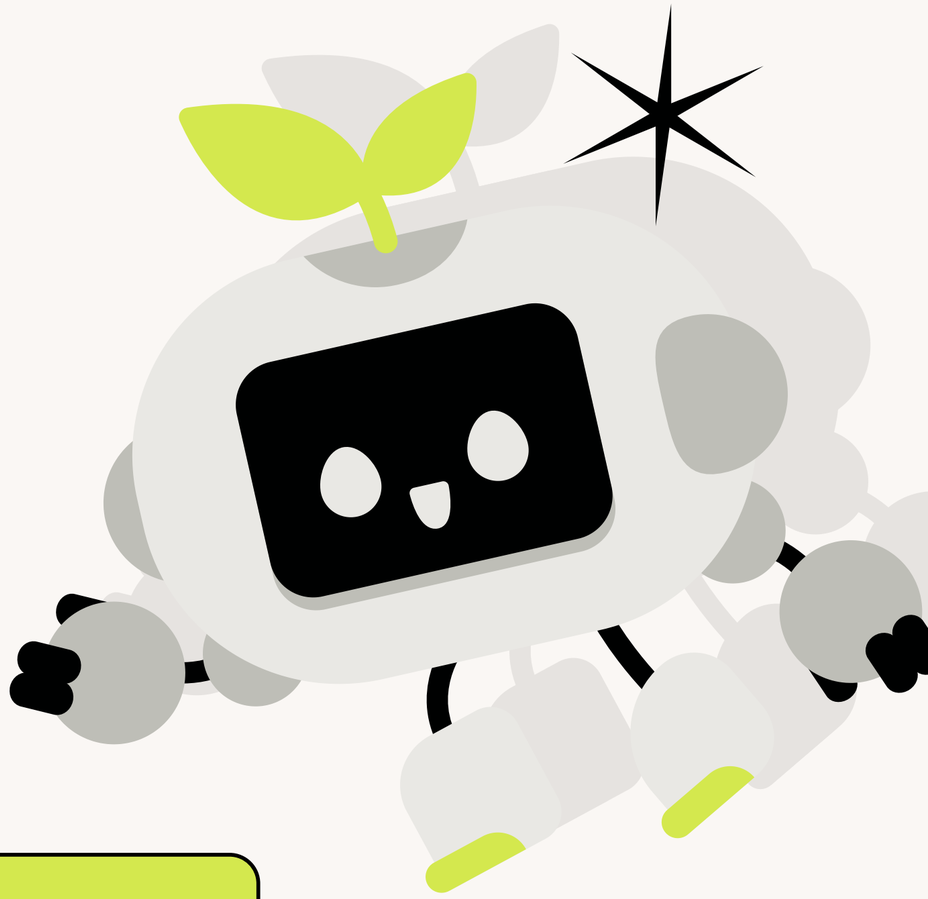


Por: Equipo 1



OBJETIVOS

Comparar el desempeño y la separabilidad de clases en la clasificación de siluetas binarias del conjunto.





Evaluar dos enfoques de extracción de características: valores de píxeles aplanados y momentos geométricos de Hu

DESCRIPCIÓN DEL CONJUNTO DE DATOS

La colección con la que se trabajó fue la MPEG-7 Core Experiment CE Shape-1, la cual es una colección de siluetas utilizada para estudiar la descripción y comparación de formas.

Se trabajó con 10 clases que fueron previamente seleccionadas del conjunto original, analizando 1000 imágenes en total de 64x64 píxeles, distribuidas equitativamente por clase.

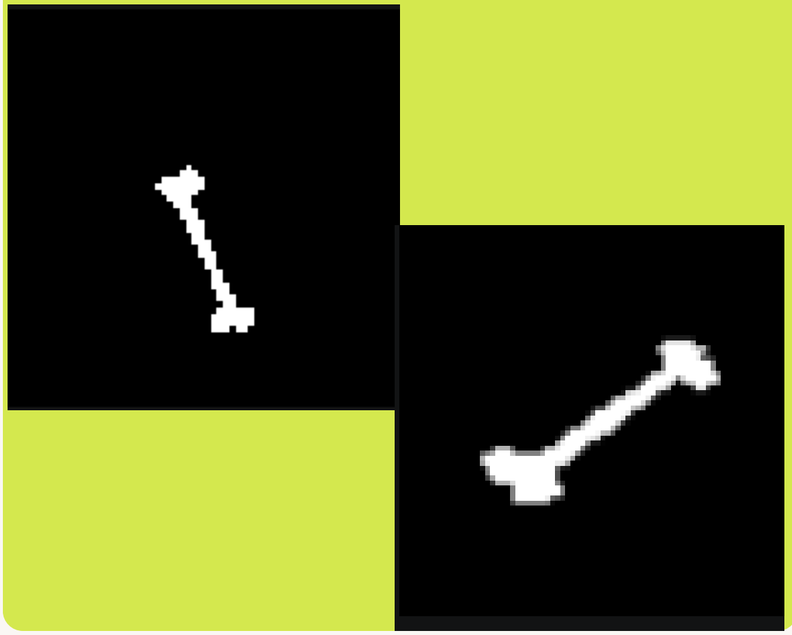
La variable objetivo es la etiqueta de clase, y el problema a resolver es la clasificación multiclase

Etiqueta en los archivos	Objeto o figura representada
`Bone`	Hueso
`bottle`	Botella
`brick`	Ladrillo o bloque
`butterfly`	Mariposa
`fork`	Tenedor
`Heart`	Corazón
`guitar`	Guitarra
`octopus`	Pulpo
`tree`	Árbol
`watch`	Reloj

FIGURAS

01

BONE



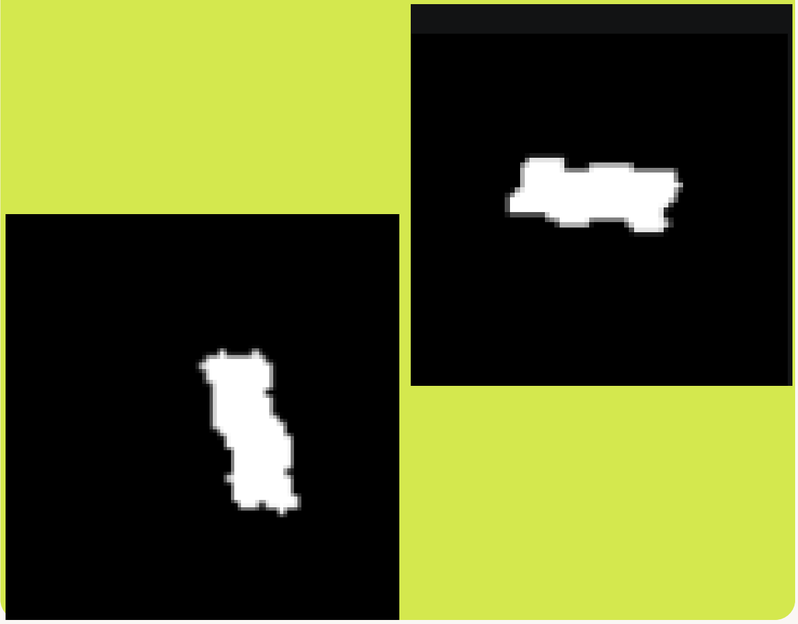
02

BOTTLE



03

BRICK



FIGURAS

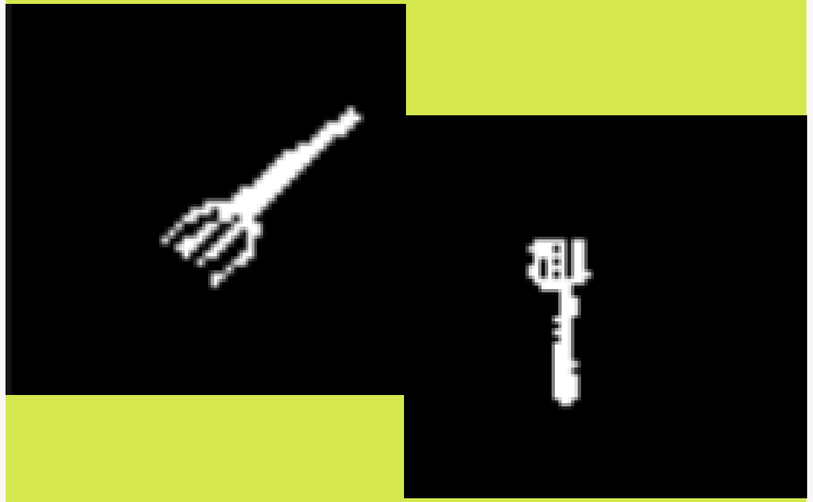
04

BUTTERFLY



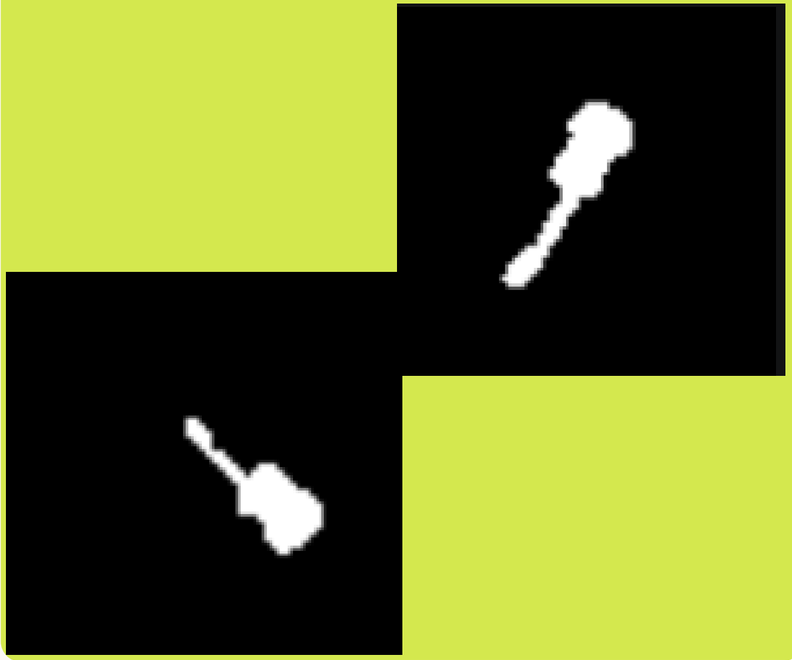
05

FORK



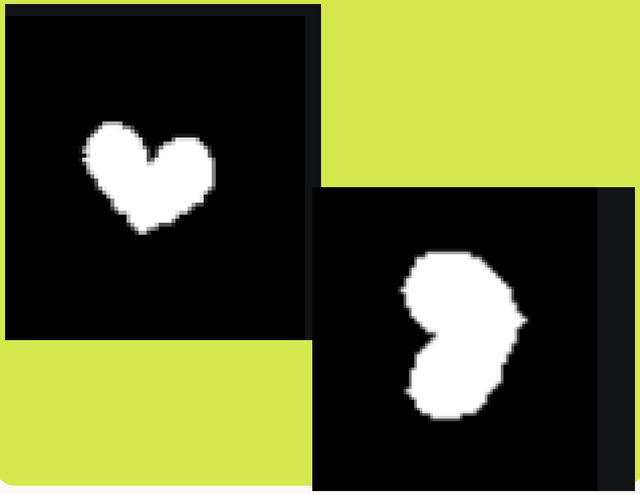
06

GUITAR



07

HEART



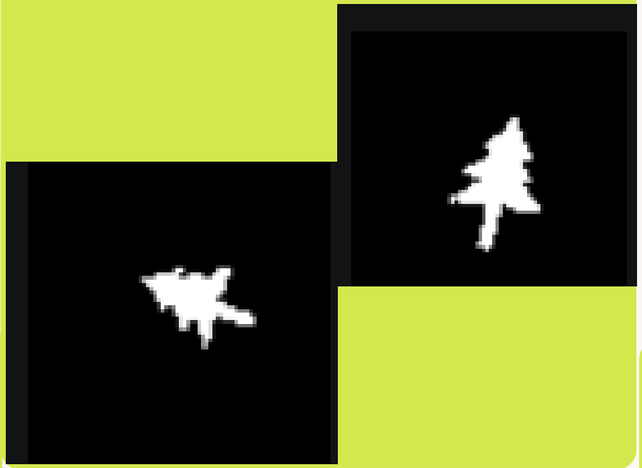
08

OCTOPUS



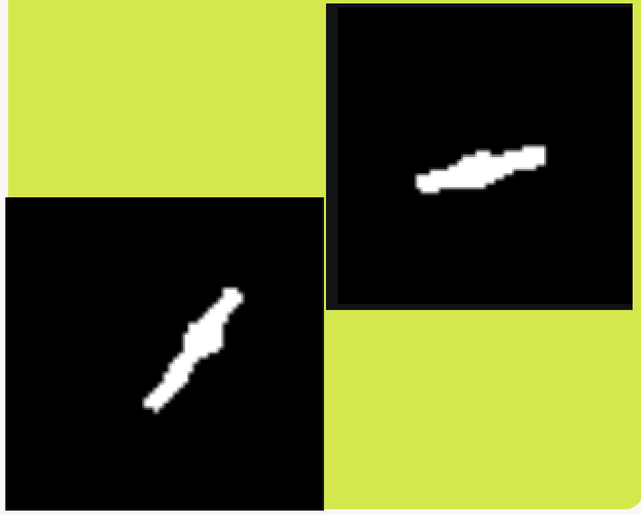
09

TREE



10

WATCH



	entrenamiento	prueba
Bone	70	30
bottle	70	30
brick	70	30
butterfly	70	30
fork	70	30
Heart	70	30
guitar	70	30
octopus	70	30
tree	70	30
watch	70	30

```
Siluetas originales en entrenamiento: 140
Siluetas originales en prueba: 60
```

DESCRIPCIÓN DEL CONJUNTO DE DATOS

Para trabajar con las imágenes, se realizó una partición de 70/30 para dividir entre prueba y entrenamiento.

- **Entrenamiento: 700 imágenes**
- **Prueba: 300 Imágenes**

Objetivo: Comparar el desempeño y separabilidad de clases para contrastar las siluetas mediante 2 representaciones dadas por los valores de los pixeles y de momentos que describen propiedades globales (pixeles planos y descriptores geométricos)

Propiedad	Representación Pixeles	Representación Momentos de Hu
Dimensiones	64 x 64 = 4096 características	7 características
Área	Aplanar la imagen: cada posición aporta una característica. Conserva el detalle espacial y depende de dónde aparece cada parte de la figura.	Resumir cómo se distribuye la masa de la silueta mediante combinaciones de momentos geométricos normalizados.
Preprocesamiento	Se produce un Escalamiento dividiendo los valores entre 255 para mantener un rango [0-1]	Aplica una transformación logarítmica e invariancia espacial, para no perder información valiosa
Comportamiento	Sensible a rotaciones, cambios de posición o escala	No cambian aunque la figura en la imagen sufra de rotación, cambios de escala (tamaño) o traslación (desplazamiento)

EXPLORACIÓN CON T-SNE

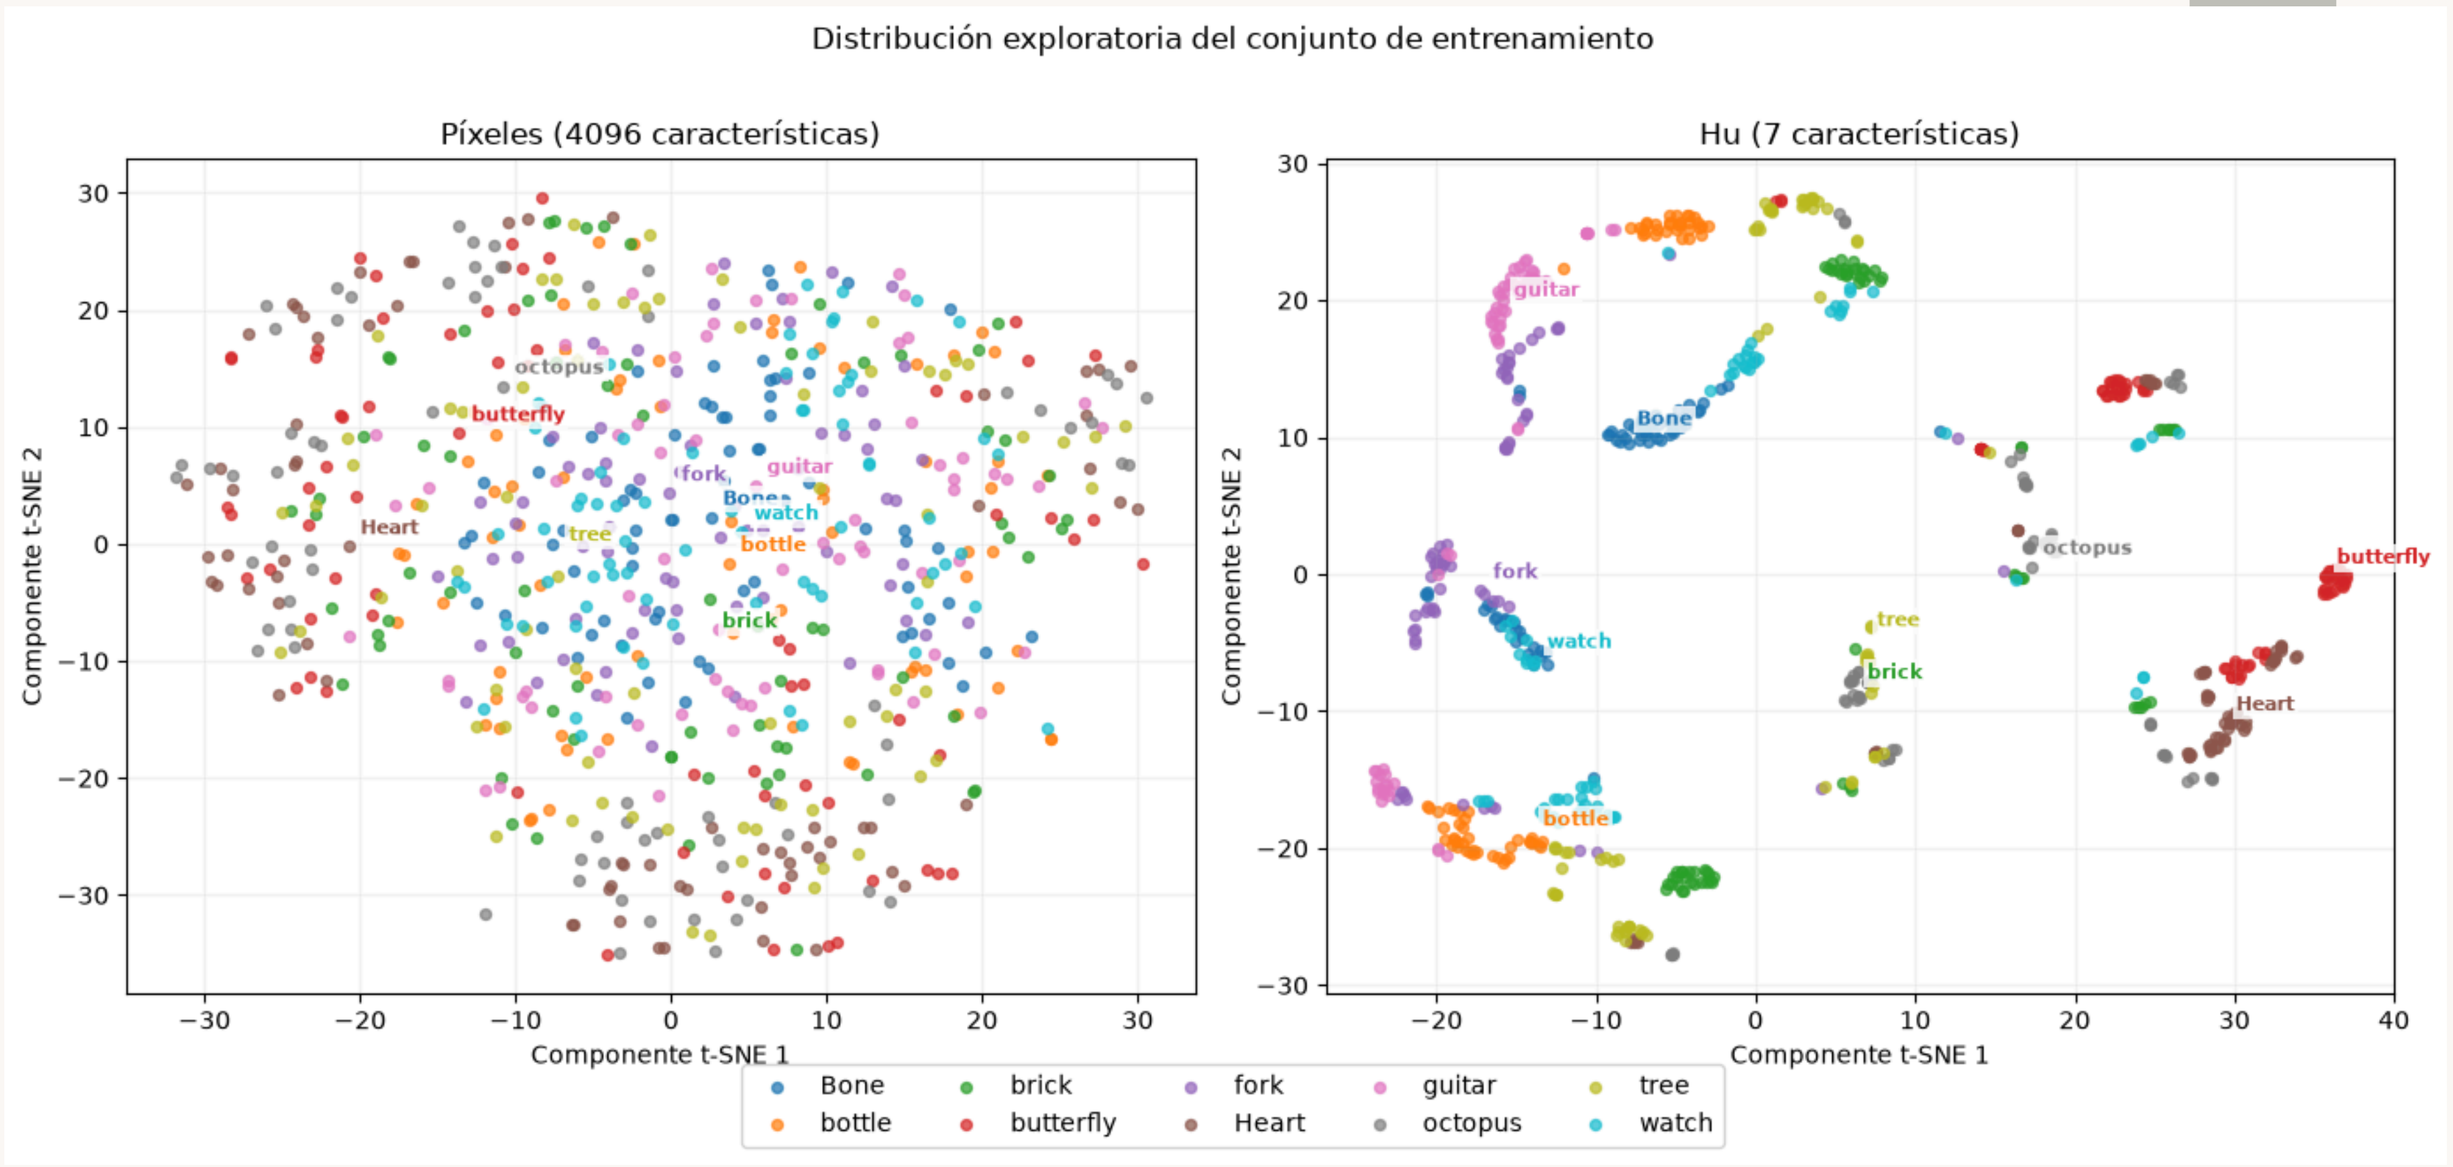
01

CONTENIDO

t-SNE proyecta a 2D conservando relaciones de vecindad. Se ajustó solo con entrenamiento (700 imágenes), con perplexity=30 y random_state=42, y las etiquetas se usan solo para colorear.

	Píxeles (4096)	Hu (7)
Estructura general	Nube dispersa, sin grupos claros	Grupos compactos y bien definidos, aunque varias clases aparecen en más de un grupo
Clases con vecindario definido	Casi ninguna (solo una ligera tendencia de `Heart`, `butterfly` y `octopus` a quedar hacia el lado izquierdo)	`Bone` y `butterfly` son las más compactas. `bottle` y `guitar` también, pero cada una en dos grupos separados
Clases mezcladas	Prácticamente todas, porque una misma clase aparece con distinta posición, rotación y tamaño	`fork` con `watch` (delgadas y alargadas), `Heart` con `octopus` (manchas compactas) y `tree` con `brick` (formas compactas e

EXPLORACIÓN CON T-SNE



EXPLORACIÓN CON T-SNE

02

INTERPRETACIÓN

- Clases definidas en Hu: Bone y butterfly son las más compactas. bottle y guitar también, pero cada una aparece en dos grupos separados.
- Clases definidas en píxeles: casi ninguna.
- Mezcladas en Hu: fork con watch (siluetas delgadas y alargadas),

PROTOCOLO EXPERIMENTAL Y MÉTRICAS

DATOS Y PARTICIÓN

- **1000 siluetas binarias de 64×64 (valores 0 y 255), 10 clases con 100 imágenes cada una: 700 de entrenamiento (70 por clase) y 300 de prueba (30 por clase).**
- **Las 1000 imágenes proceden de 200 siluetas originales de MPEG-7 (20 por clase). Ninguna silueta original aparece a la vez en entrenamiento y prueba, así que no hay fuga de información entre conjuntos.**
- **La partición es única y se conserva en toda la práctica.**

PREPARACION POR REPRESENTACION

	Píxeles	Hu
Características	4096 (imagen aplanada)	7 momentos invariantes
Transformación	Se divide entre 255, para valores 0/1	Logaritmo con signo conservado ($-\text{signo}\cdot\log_{10}\lvert h\rvert$, con piso de 1e-30) y luego `StandardScaler`
Pipeline	Solo el clasificador	`StandardScaler` + clasificador

- **El escalador de Hu se ajusta solo con entrenamiento, dentro del pipeline. El conjunto de prueba solo se usa en predict y en las métricas.**

PROTOCOLO EXPERIMENTAL Y MÉTRICAS

MODELOS

- Antes: "perceptrón multicapa con una capa oculta de 100 neuronas, random_state=42 y max_iter=500; regresión logística con max_iter=500".
- Ahora: "Hiperparámetros por defecto en todos los modelos, salvo el perceptrón multicapa: una capa oculta de 100 neuronas, random_state=42 y max_iter=500".
- MLP (agregar): max_iter=500 se usó para darle más margen de iteraciones, pero el modelo no convergió: el aviso de que se alcanzó el máximo sigue apareciendo. Hay que decirlo y reconocer que limita la interpretación de sus resultados.

MODELOS

ESTRATEGIAS MULTICLASE (AMPLIAR): ADEMÁS DE NOMBRARLAS, EXPLÍCALAS Y MENCIONA LA VERIFICACIÓN.

- UNA CONTRA EL RESTO (PERCEPTRÓN): UN CLASIFICADOR POR CLASE CONTRA LAS OTRAS 9, ES DECIR, 10 CLASIFICADORES. GANA LA CLASE CON MAYOR PUNTUACIÓN.
- UNO CONTRA UNO (SVM): UN CLASIFICADOR POR CADA PAR DE CLASES, ES DECIR, 45 CLASIFICADORES. LA CLASE FINAL SE DECIDE POR VOTACIÓN.
- MULTINOMIAL (REGRESIÓN LOGÍSTICA): UN SOLO MODELO QUE ASIGNA PROBABILIDADES A LAS 10 CLASES A LA VEZ.
- VERIFICACIÓN: DESPUÉS DEL AJUSTE SE COMPROBÓ QUE CADA MODELO TIENE 10 ETIQUETAS EN CLASSES_.

PROTOCOLO EXPERIMENTAL Y MÉTRICAS

MÉTRICAS:

- Exactitud: proporción de imágenes bien clasificadas.
- F1 macro: para cada clase c se calcula $F1_c = 2 \cdot P_c \cdot R_c / (P_c + R_c)$, con precisión P_c y exhaustividad R_c, y se promedian las diez con el mismo peso.
- Si una clase nunca se predice, su precisión tiene denominador cero. Hasta donde sé, scikit-learn le asigna 0 por defecto y lanza un aviso; conviene confirmarlo en la documentación antes de afirmarlo en la presentación.
- Con clases equilibradas, la exactitud y el F1 macro son parecidos, y el F1 baja respecto a la exactitud cuando los aciertos se concentran en pocas clases.

MÍNIMA DISTANCIA Y KNN

01

CÓMO FUNCIONA CADA UNO

- **Mínima distancia (NearestCentroid): calcula el centroide de cada clase y asigna la clase del centroide más cercano.**
- **KNN (KNeighborsClassifier): hiperparámetros por defecto, k = 5 y distancia euclidiana. Clasifica por mayoría entre los 5 vecinos más cercanos.**

Tabla de resultados

Algoritmo	Representación	Exactitud entren.	F1 entren.	Exactitud prueba	F1 prueba
Mínima distancia	Píxeles	0.3857	0.3796	0.2000	0.1997
Mínima distancia	Hu	0.7414	0.7388	0.6533	0.6503
KNN	Píxeles	0.5100	0.5031	0.2333	0.2086
KNN	Hu	0.9314	0.9311	0.7600	0.7586

MÍNIMA DISTANCIA Y KNN

MENSAJES CLAVE

•Hu supera por mucho a los píxeles en prueba: 0.653 contra 0.200 en mínima distancia y 0.760 contra 0.233 en KNN. Con píxeles, ambos están cerca del azar de 0.10 solo por poco.

•KNN con Hu pasa de 0.93 en entrenamiento a 0.76 en prueba. Es una brecha de unos 17 puntos, con algo de sobreajuste, pero con buen nivel de prueba.

MENSAJES CLAVE

•Mínima distancia generaliza más estable (0.74 a 0.65), pero con menor techo, porque un solo centroide por clase no captura clases con formas variadas.

•KNN con píxeles tiene F1 (0.209) por debajo de la exactitud (0.233): acierta en pocas clases (Heart, bottle, brick) y falla en el resto.

MÍNIMA DISTANCIA Y KNN

ERRORES PRINCIPALES EN PRUEBA CON HU	ERRORES PRINCIPALES EN PRUEBA CON PÍXELES
Mínima distancia: Bone se confunde con watch (10 de 30), butterfly con Heart (12 de 30), Heart con tree (9 de 30) y guitar con fork (10 de 30).	Mínima distancia: octopus se predice como Heart (11 de 30), watch como fork (12) y bottle como guitar (10).
KNN: Bone con watch (11 de 30) y guitar con fork (8 de 30). butterfly y Heart salen casi perfectos (29/30 y 30/30).	KNN: butterfly y octopus caen en Heart (16 y 13).

PERCEPTRÓN Y REGRESIÓN LOGÍSTICA

Estrategias Lineales para 10 clases

Perceptrón

	Representación	Conjunto	Exactitud	F1 macro
0	Píxeles	Entrenamiento	1.0000	1.0000
1	Píxeles	Prueba	0.1933	0.1879
2	Hu	Entrenamiento	0.7314	0.7202
3	Hu	Prueba	0.6467	0.6215

Regresión logística

	Representación	Conjunto	Exactitud	F1 macro
0	Píxeles	Entrenamiento	1.0000	1.0000
1	Píxeles	Prueba	0.2100	0.2109
2	Hu	Entrenamiento	0.8543	0.8527
3	Hu	Prueba	0.7433	0.7416

Perceptrón	Regresión Logística
Uno contra el resto. 10 clasificadores binarios independientes	Un solo modelo con 10 vectores de pesos entrenados en conjunto
Corrige sus pesos solo cuando se equivoca	Salida softmax: probabilidades que suman 1
Se asigna la clase de mayor puntuación	Minimiza la entropía cruzada con regularización L2

Hiperparámetros predeterminados. Verificamos que classes_ contiene las 10 etiquetas en cada modelo.

Perceptrón y regresión logística: con píxeles no generalizan; con Hu alcanzan 65–74 % en prueba

- Con píxeles, ambos alcanzan 1.0000 en entrenamiento y 0.19–0.21 en prueba (el azar con 10 clases es 0.10).
- Con Hu, la exactitud de prueba es 0.6467 (perceptrón) y 0.7433 (regresión logística).
- Con Hu, la brecha entre entrenamiento y prueba es moderada: 0.7314 → 0.6467 (perceptrón) y 0.8543 → 0.7433 (regresión logística).

PERCEPTRÓN MULTICAPA

¿CÓMO FUNCIONA?

Es una red neuronal con una capa de entrada, una de salida y una o más capas ocultas. Las funciones de activación le permiten al modelo clasificar datos no linealmente separables.

Representación	Conjunto	Exactitud	F1 prueba
Píxeles	Entrenamiento	1	1
Píxeles	Prueba	0.2133	0.2077
Hue	Entrenamiento	0.9671	0.9672
Hue	Pruba	0.7667	0.7646

MENSAJES CLAVE

- MEMORIZA: 100 % EN ENTRENAMIENTO AL TRABAJAR CON PÍXELES .
- CON **HU PRESENTA LA MAYOR EXACTITUD** SOBRE LOS DATOS DE PRUEBA ENTRE TODOS LOS MODELOS.
- CONFUNDE MUCHO LAS CLASES **BONE** CON **WATCH**, VICEVERSA Y **GUITAR** CON **FORK**,
- A PESAR DE **NO CONVGER** TRAS 500 ITERANCIONES, ES EL MODELO QUE MEJOR GENERALIZÓ.

MÁQUINA DE SOPORTE VECTORIAL (SVM)

¿CÓMO FUNCIONA?

Encuentra el hiperplano óptimo para separar clases. Su objetivo es maximizar el margen de separación utilizando los puntos más cercanos (vectores de soporte), aplicando funciones kernel para clasificar eficientemente datos no linealmente separables.

Representación	Conjunto	Exactitud	F1 prueba
Píxeles	Entrenamiento	0.7943	0.795
Píxeles	Prueba	0.2533	0.25
Hue	Entrenamiento	0.8557	0.8538
Hue	Pruba	0.72	0.7215

MENSAJES CLAVE

- **MODELO MÁS EXACTO USANDO PÍXELES**.
- ES UNO DE LOS MODELOS CON **MENOR BRECHA DE EXACTITUD ENTRENAMIENTO-PRUEBA** (13.6)
- CONFUNDE LAS CLASES **BONE** CON **WATCH**, VICEVERSA Y **HEART** CON **TREE**

ÁRBOL DE DECISIÓN

¿CÓMO FUNCIONA?

Divide los datos con preguntas sobre una característica (¿supera un umbral?) hasta que cada hoja contiene una sola clase. Criterio gini y sin límite de profundidad. Los 700 ejemplos de entrenamiento son solo 140 siluetas × 5 variantes.

Representación	Entrenamiento	Prueba	F1 prueba
Píxeles	1.000	0.2567	0.2565
Hu	1.000	0.71	0.7043

MENSAJES CLAVE

- Memoriza: 100 % en entrenamiento con ambas representaciones.
- Con Hu cae de 1.00 a 0.71, la mayor brecha de los ocho algoritmos ≈29 pts.
- En el notebook es 6.° de 8 con Hu (solo supera a mínima distancia y perceptrón); con píxeles es el más alto (0.257), aún cerca del azar.
- Errores con Hu: Bone→watch y fork→guitar (14 de 30), guitar→fork (11), octopus→Heart (10).
- Profundidad 9 y unas 55 hojas con Hu; con píxeles, profundidad 21 y unas 293 hojas para 700 ejemplos.

BAYES INGENUO

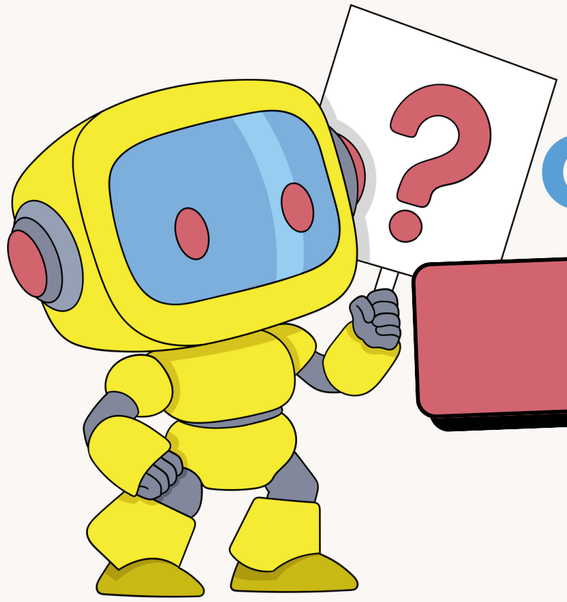
¿CÓMO FUNCIONA?

Modela cada característica de cada clase con una gaussiana (media y varianza) y supone que las características son independientes. Variante gaussiana, valores por defecto.

Representación	Entrenamiento	Prueba	F1 prueba
Píxeles	0.390	0.120	0.108
Hu	0.830	0.713	0.717

MENSAJES CLAVE

- Con píxeles es el peor modelo: 0.12 en prueba, cerca del azar (0.10).
- Con píxeles colapsa: predice «tree» en 131 de 300 imágenes de prueba (44 %); brick acierta 0 de 30.
- Con Hu es 5.° de 8 (0.713) en el notebook, pierde ≈12 pts y rinde como el árbol (0.68–0.72) siendo más simple.
- Errores con Hu: Bone→watch, butterfly→Heart y fork→guitar (10 de 30 cada uno), Heart→tree (9); octopus 30/30.
- Causa del colapso: varianzas casi nulas por píxel; si la silueta cabe en la zona de variación de «tree», gana siempre (131 de 131).



COMPARACIÓN GLOBAL

- La representación pesa más que el algoritmo: con píxeles, 0.12–0.26 en prueba (azar: 0.10); con Hu, 0.65–0.77
- Con píxeles hay sobreajuste: cuatro modelos llegan a 1.0000 en entrenamiento y caen a 0.19–0.26 en prueba; memorizan en lugar de generalizar
- Exactitud y F1 macro coinciden en lo esencial: difieren como máximo 0.025. La mayor diferencia (perceptrón con Hu) se debe a confusiones concentradas, como butterfly → Heart (22 de 30)

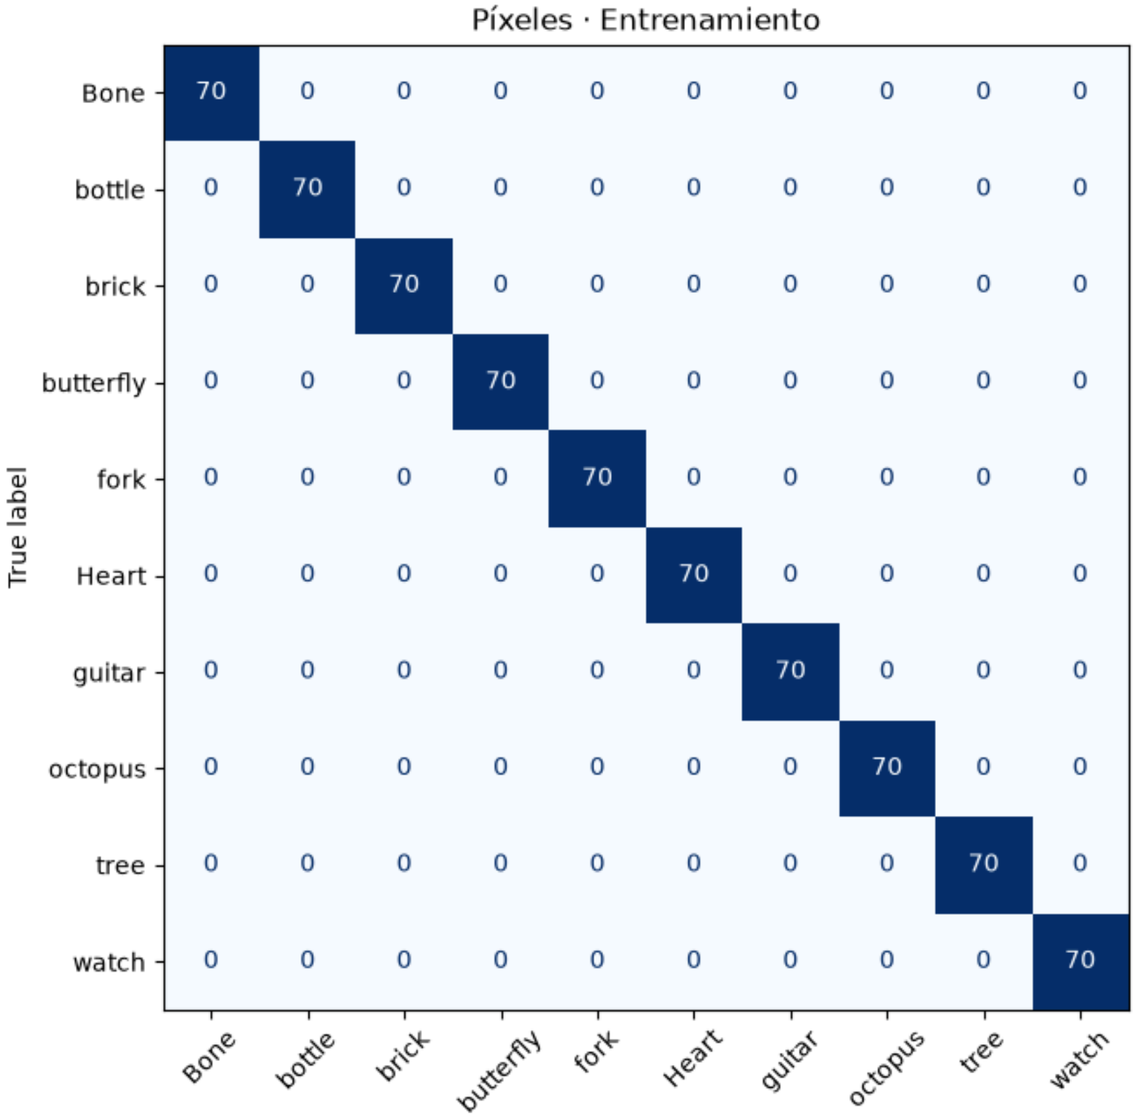
Algoritmo	Píxeles entren.	Píxeles prueba	Hu entren.	Hu prueba
Mínima distancia	0.3857	0.2000	0.7414	0.6533
KNN	0.5100	0.2333	0.9314	0.7600
Perceptrón	1.0000	0.1933	0.7314	0.6467
Perceptrón multicapa	1.0000	0.2133	0.9671	0.7667
SVM	0.7943	0.2533	0.8557	0.7200
Árbol de decisión	1.0000	0.2567	1.0000	0.7100
Bayes ingenuo	0.3900	0.1200	0.8300	0.7133
Regresión logística	1.0000	0.2100	0.8543	0.7433

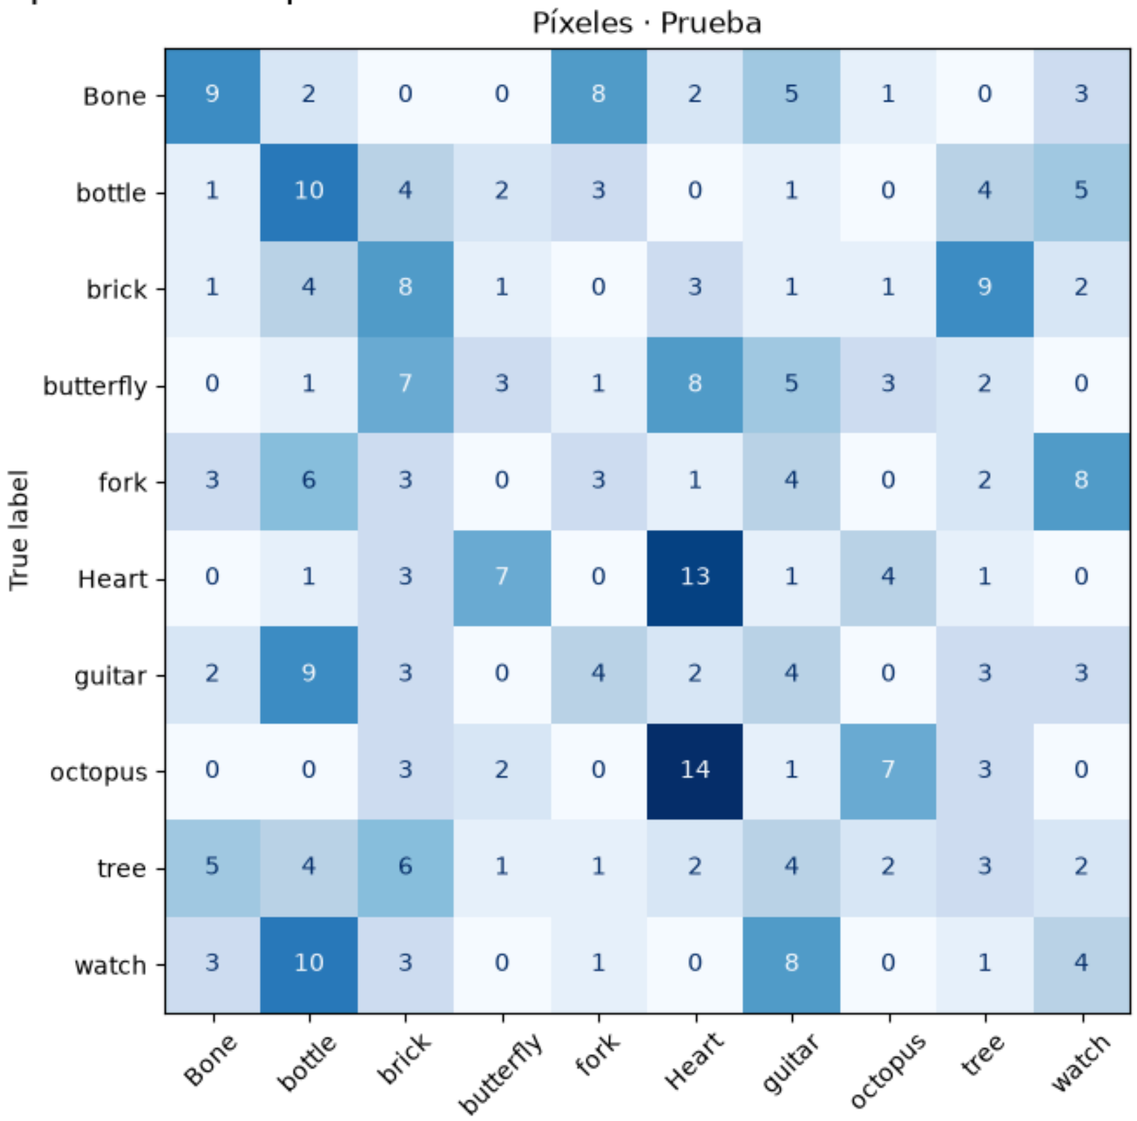
El árbol de decisión no tiene semilla fijada; sus cifras pueden variar entre ejecuciones

MATRICES DE CONFUSIÓN

A continuación se presentan las matrices de confusión que encontramos más interesantes.

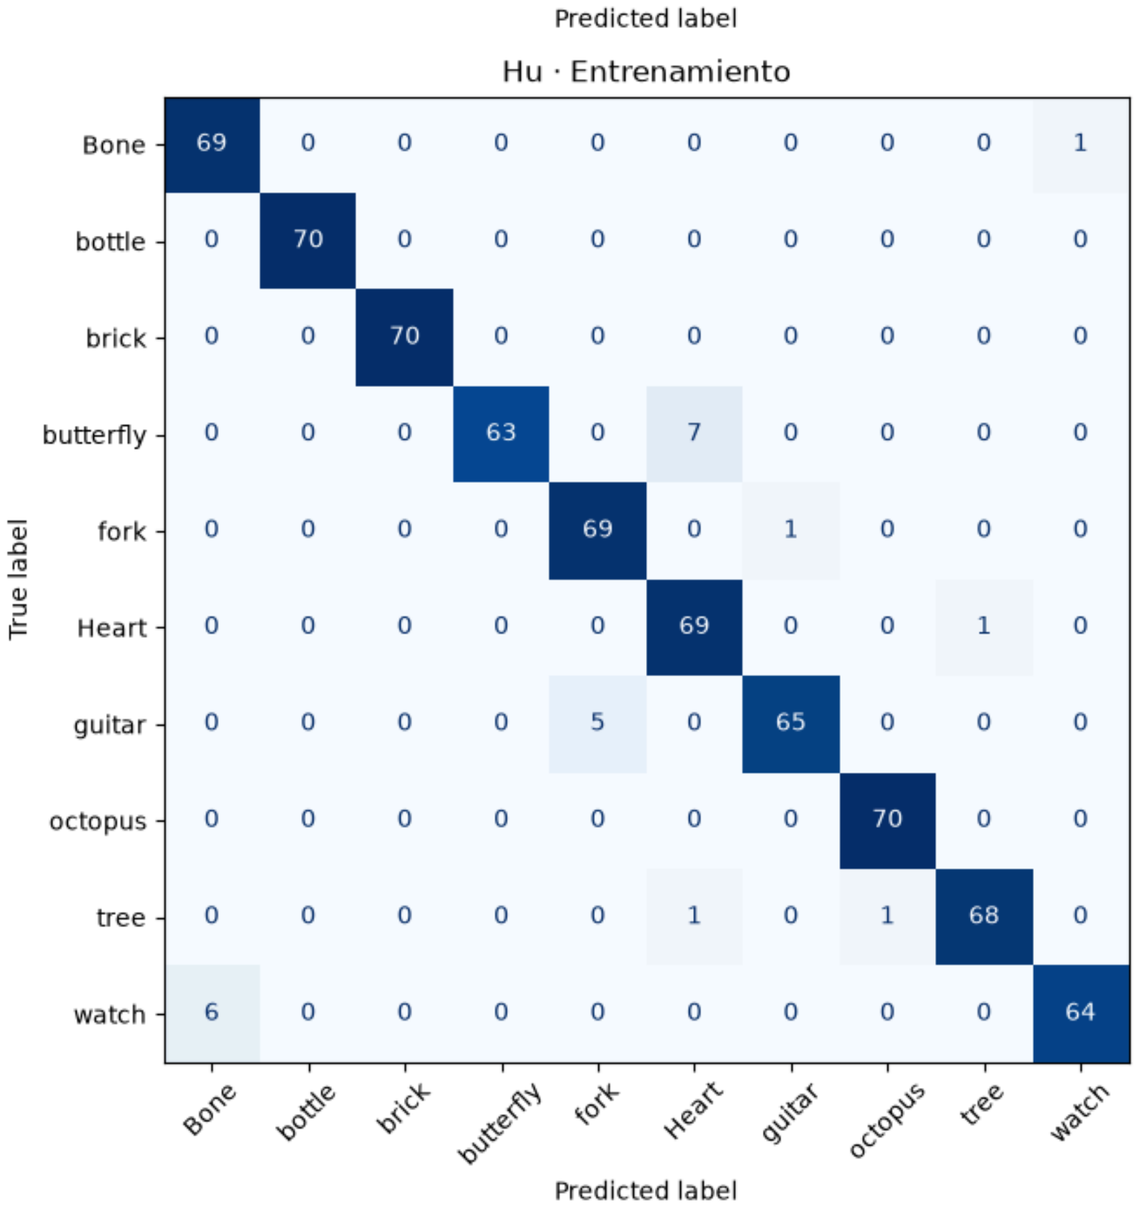
Matrices de confusión: Perceptrón multicapa

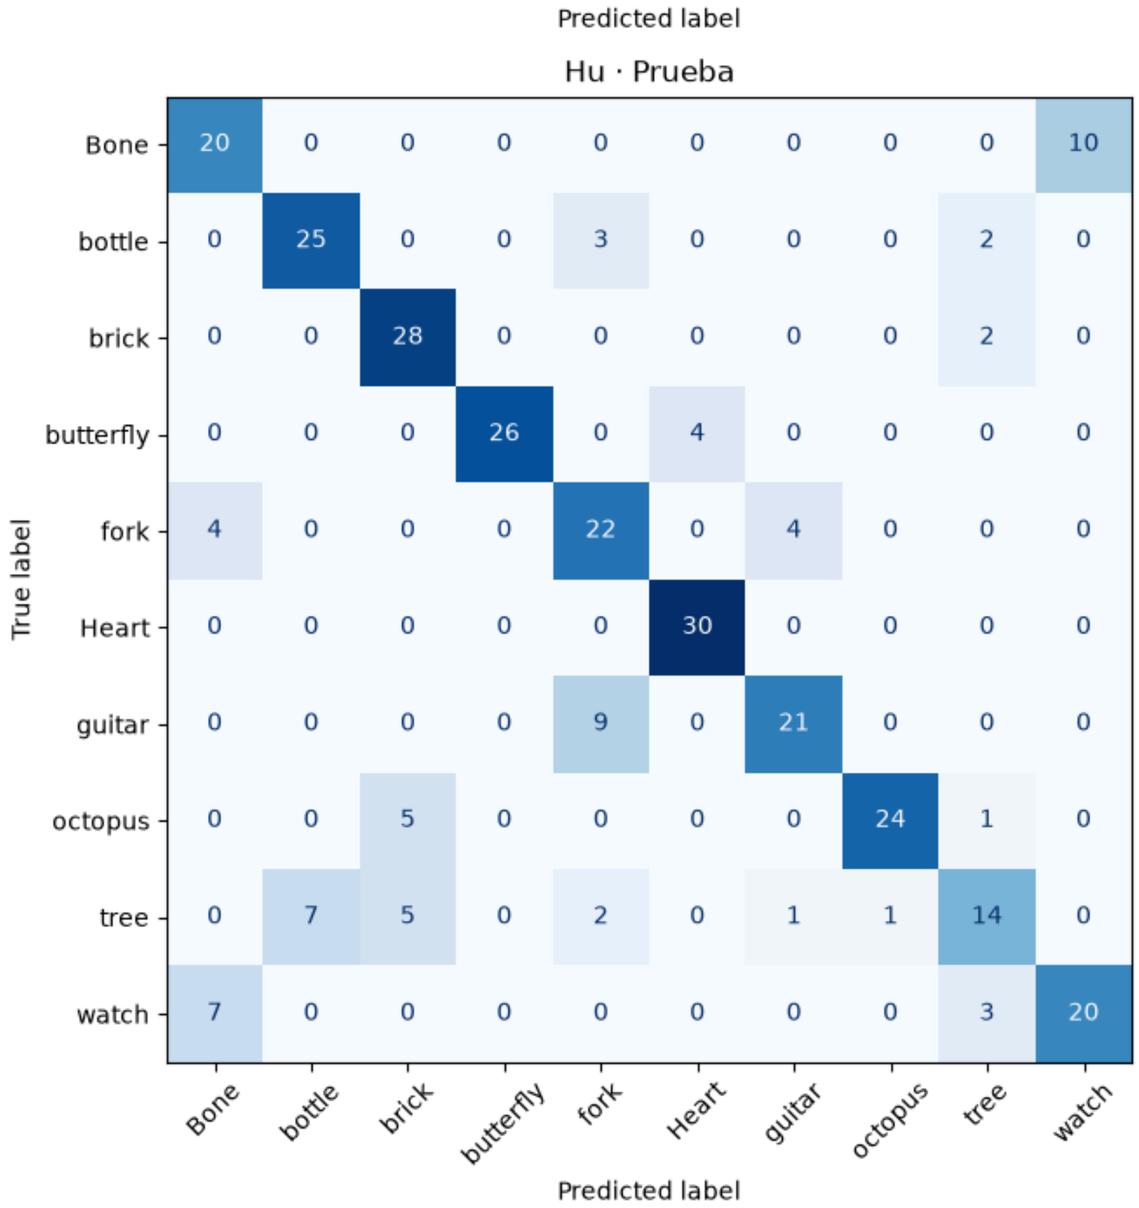




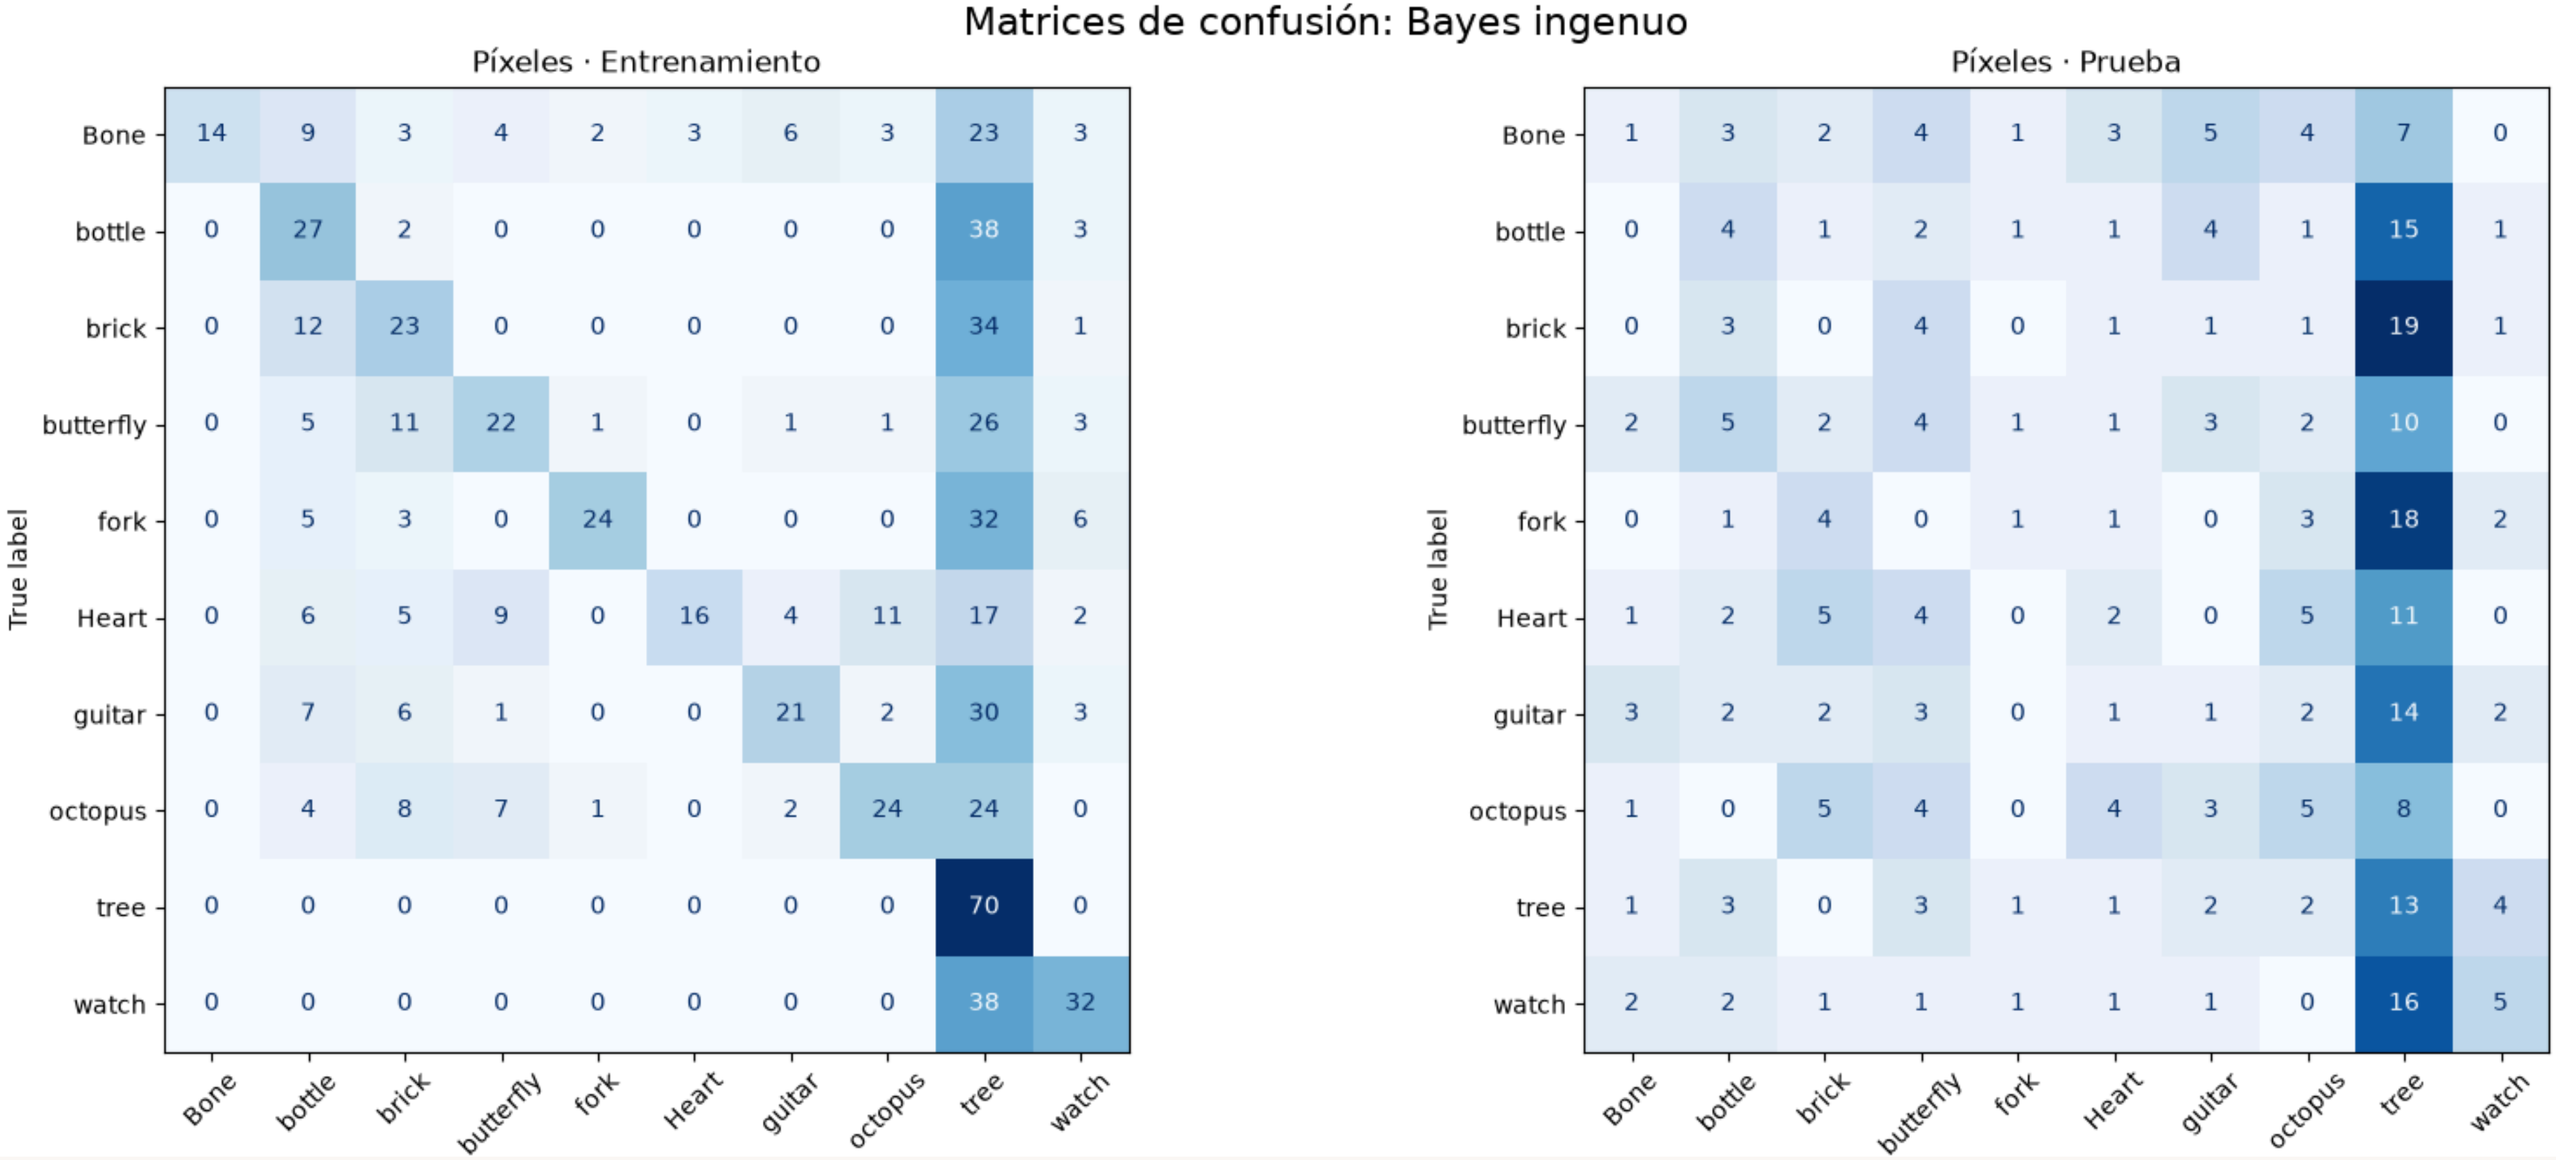
Se aprecia un **gran subajuste**.

Perceptrón multicapa



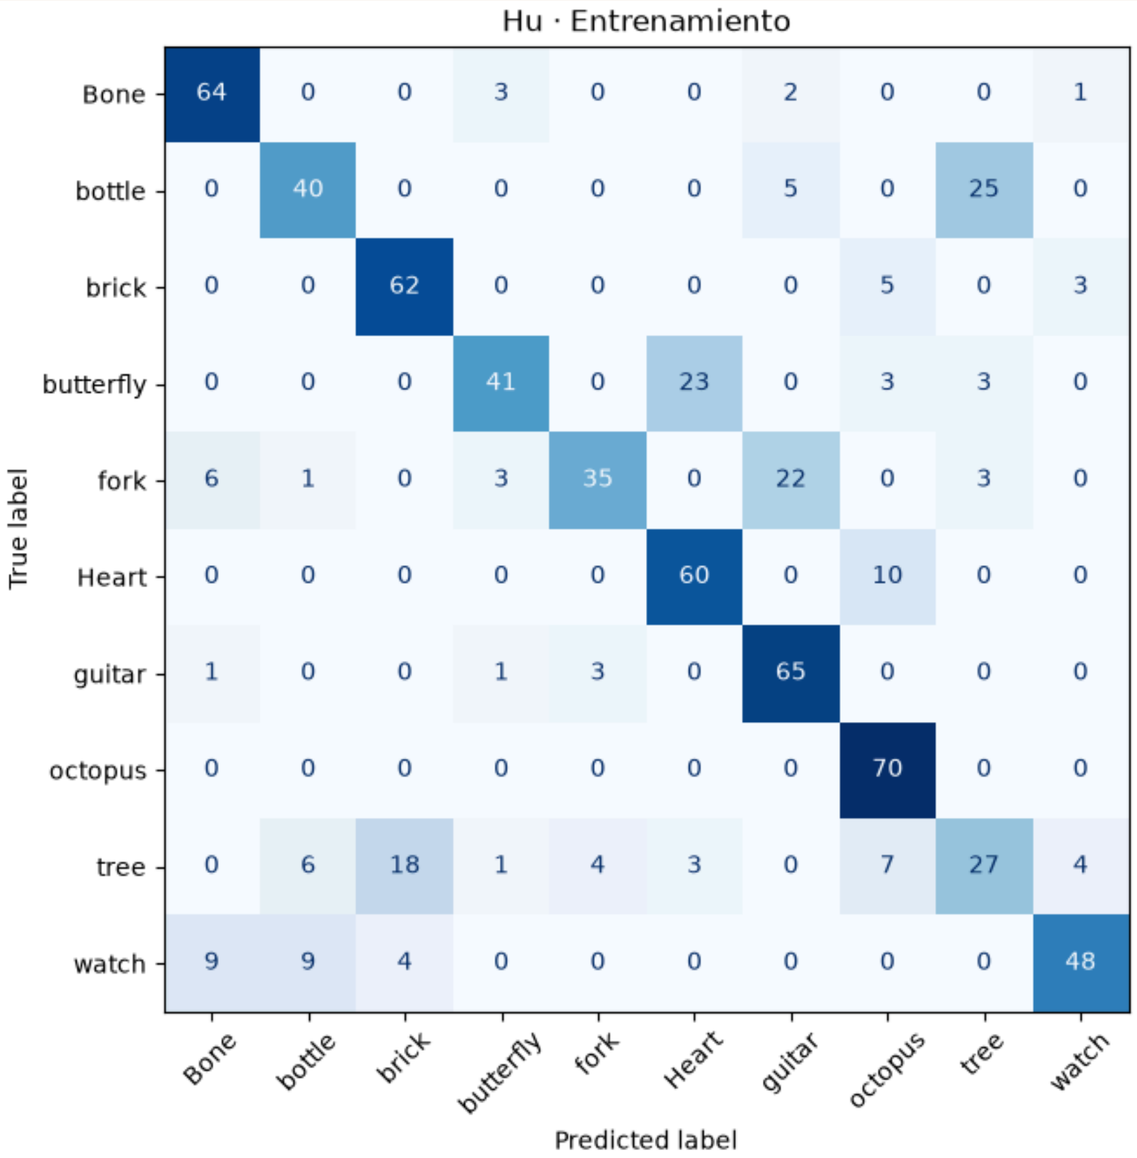


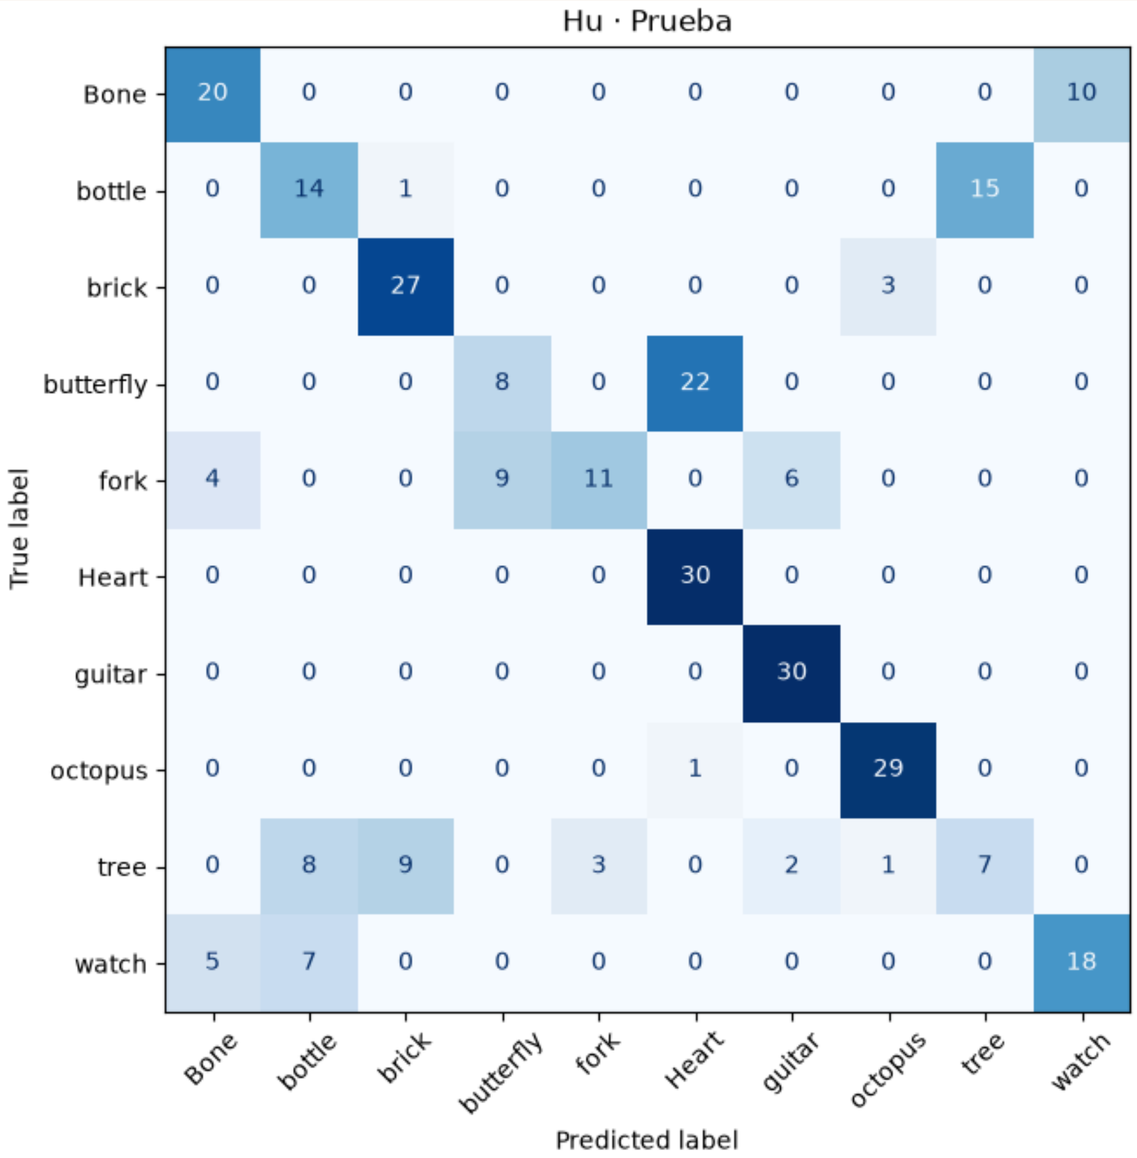
Se aprecia una gran **mejora en la generalización** del modelo.



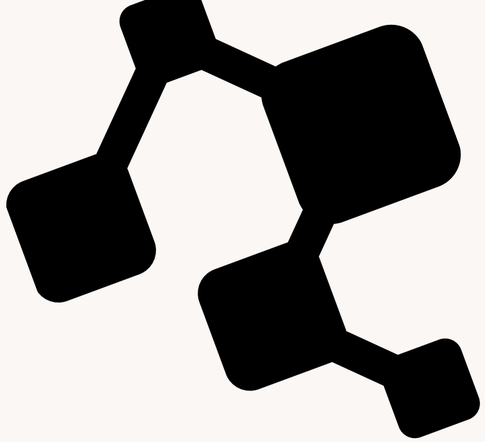
La varianza de la clase **tree** atrae las predicciones de casi cualquier vector desconocido al asumir independencia y normalidad.

Perceptrón





De 30 siluetas de butterfly, 22 son clasificadas como Heart. Esto indica que esas clases **no son linealmente separables**.



CONVERGENCIA Y LIMITACIONES

Avisos

- Mínima distancia con píxeles: hay píxeles con desviación cero dentro de una clase; no invalida el resultado.
- Regresión logística con píxeles: lbfgs no convergió en 100 iteraciones (valor predeterminado).
- MLP con Hu: no convergió en 500 iteraciones; su 0.7667 se interpreta con cautela.

Limitaciones

- Una sola partición: 60 siluetas distintas en prueba; sin medias ni desviaciones.
- Hiperparámetros predeterminados, salvo el MLP
- Hu es invariante solo de forma aproximada y, con 7 números, pierde detalle local

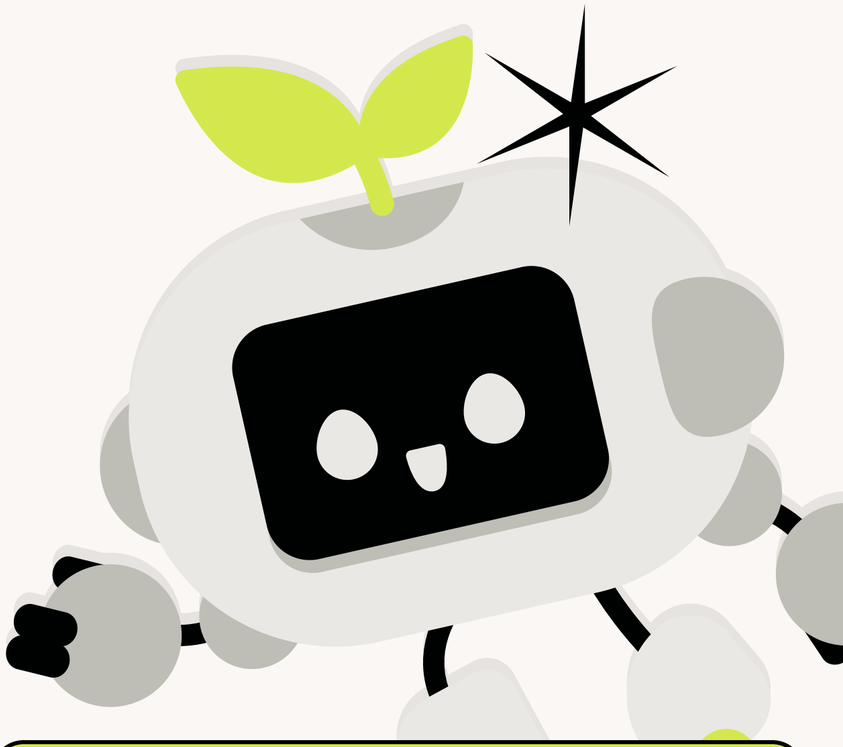
CONCLUSIONES

01. LA REPRESENTACIÓN PESA MÁS

Con Hu, los ocho algoritmos logran 65–77 % en prueba; con píxeles, solo 12–25 %.

02. ERRORES DE FORMA GLOBAL

Con Hu se confunden Bone↔watch, guitar↔fork y butterfly→Heart: siluetas alargadas o compactas parecidas.



03. MÁS CAPACIDAD, MÁS SOBRE-AJUSTE

Con Hu, la brecha entrenamiento–prueba es de 29 puntos en el árbol (según la corrida), 20 en el MLP y 17 en KNN, y de 11–12 en regresión logística y Bayes.

Usar momentos de Hu. Entre los mejores modelos, la exactitud en prueba difiere unos 2 puntos, así que conviene mirar también la brecha:

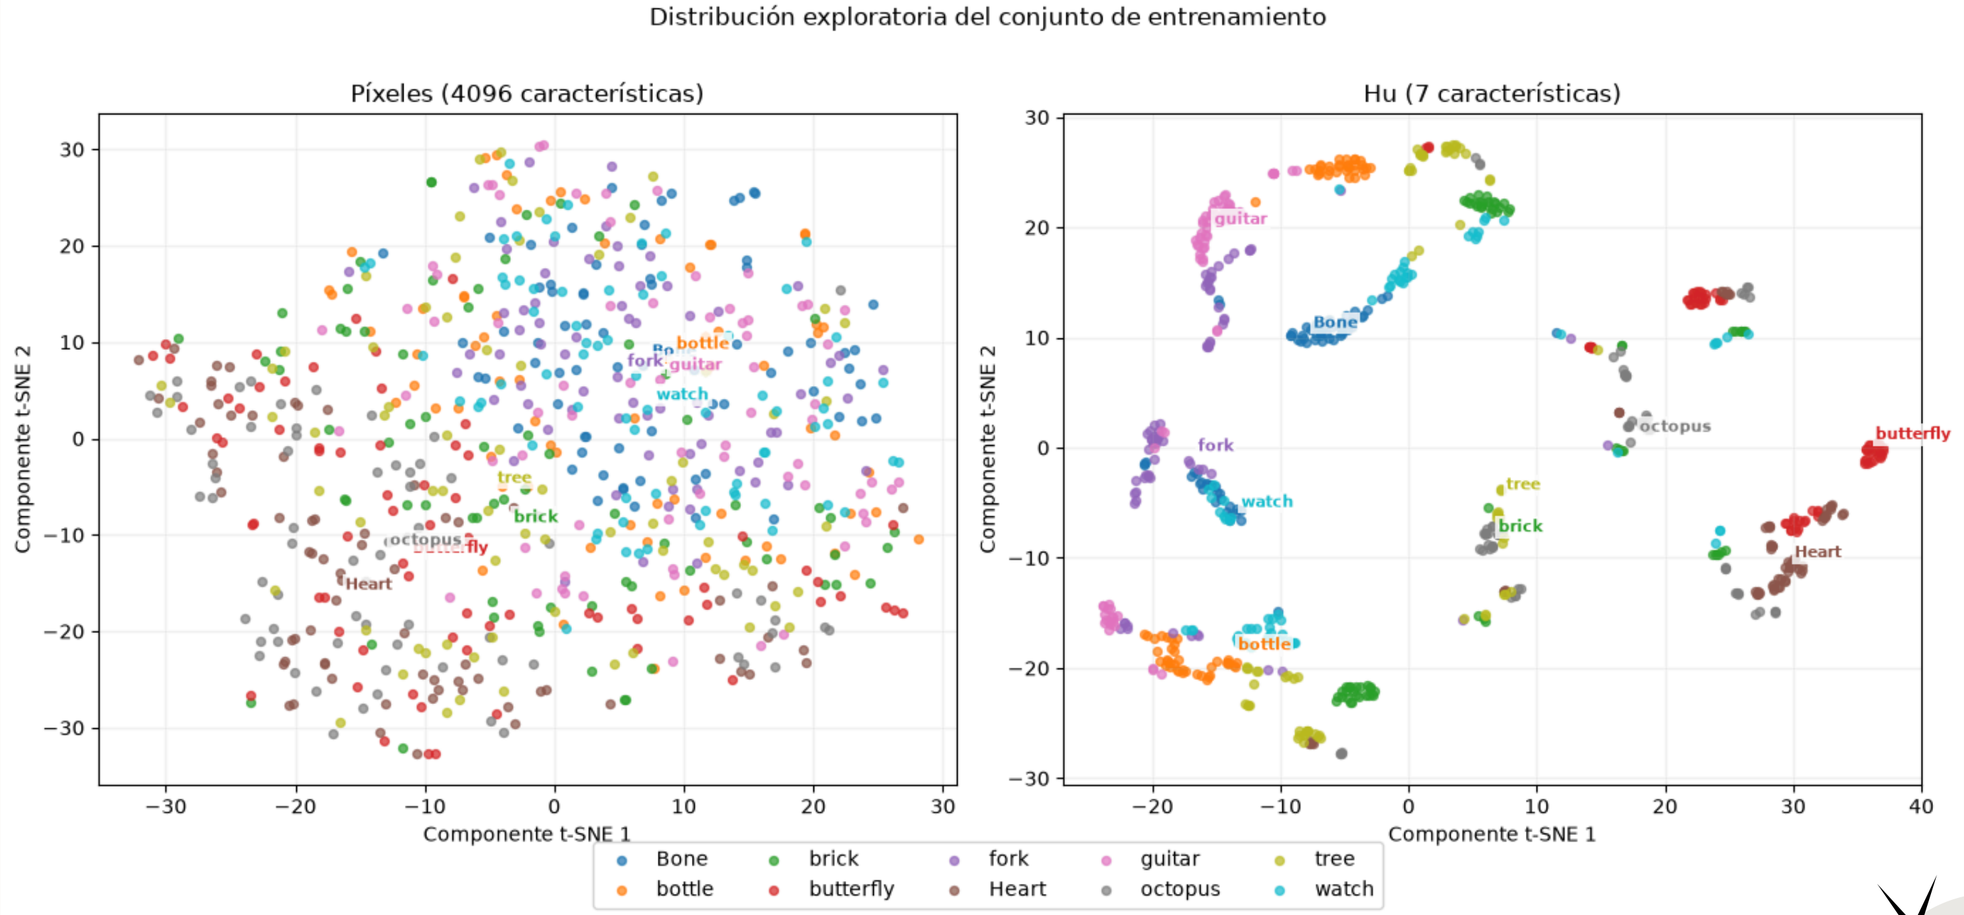
Modelo (Hu)	Prueba	Brecha	Nota
MLP	0.767	20 pts	No convergió
KNN	0.760	17 pts	Sin entrenamiento
Reg. logística	0.743	11 pts	Converge

Opción equilibrada: regresión logística, la de menor brecha (11 pts) y la que converge sin problemas.

SIGUIENTES PASOS

- **Validación cruzada agrupada por silueta original.**
- **Ajustar hiperparámetros solo con validación cruzada en entrenamiento.**
- **Añadir descriptores de forma: excentricidad, solidez, Fourier.**
- **Fijar la semilla del árbol y repetir con varias semillas.**

RECOMENDACIÓN


Distribución exploratoria del conjunto de entrenamiento
Píxeles (4096 características)
Hu (7 características)
Componente t-SNE 1
Componente t-SNE 2
Bone
bottle
brick
butterfly
fork
Heart
guitar
octopus
tree
watch

GRACIAS

